



**INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO**



BASES DE DATOS

Práctica 2:

"Modelo Entidad-Relación Extendido: proyecto propio y proyecto asignado"

Ejercicio 3. Lectura y resumen de tres artículos

Profesor: Hurtado Avilés Gabriel

Equipo:

Espinosa Ramirez José Luis
Rojas Castro Alejandro Tonatiuh
Zamudio Monroy Gael Armando

Grupo: 3BV1

Fecha de Entrega: 8 de octubre de 2026

Artículo 1. Cuando México tiembla: la historia contada por los datos.

¿Qué problema aborda?

México se ubica en el Cinturón de Fuego del Pacífico y en su territorio interactúan cinco placas tectónicas, las cuales son:(placa norteamericana,placa del pacifico,placa de cocos,placa de rivera y placa del caribe) por lo que cerca del 70 % del país está expuesto a riesgo sísmico, incluidas zonas muy pobladas como el Valle de México y Guadalajara. Los sismos no pueden predecirse, pero sí estudiarse con datos confiables. El Servicio Sismológico Nacional (SSN) publica información de los sismos ocurridos desde 1900; sin embargo, estos datos son técnicos, poco visuales y difíciles de manejar para la mayoría de las personas. El artículo plantea cómo transformar esa información en algo accesible para cualquier persona, y propone un sistema web de visualización de datos sísmicos que además relaciona los sismos con información demográfica y económica.

Procesamiento de datos

Fuentes: el catálogo de sismos del SSN, con más de 300 000 eventos registrados en México desde 1900 (125 años de datos), y dos conjuntos del INEGI: el Censo de Población y Vivienda 2020 y los Censos Económicos.

Tratamiento: aunque las bases están bien construidas, contienen registros incorrectos. Se desarrolló un programa en Python que lee los CSV, detecta campos vacíos, coordenadas inconsistentes y formatos incompatibles, y elimina los registros inválidos. Con los datos validados, el programa genera un código SQL que se ejecuta en PostgreSQL para crear la base de datos .

Modelado de la información

La información validada de sismos, población y economía se organiza en un almacén de datos con esquema dimensional. La vista de la base de datos que muestra el artículo (Figura 6) permite identificar sus elementos:

- **Dimensiones:** dim_sismos (características de cada sismo, como magnitud, profundidad, ubicación y fecha), dim_tiempo (fecha del evento), dim_zonas (localidades y su población) y dim_economia (actividad económica por zona).
- **Hechos:** fact_impacto_sismos_imputed, que registra el impacto de cada sismo sobre las zonas cercanas. Entre las medidas que el sistema reporta están la magnitud, la profundidad, el número de sismos y la población potencialmente afectada.
- **Relación:** la tabla de hechos se vincula con las cuatro dimensiones, de modo que cada sismo se puede cruzar con el momento en que ocurrió, las localidades cercanas a su epicentro y su población y economía.

El artículo es de divulgación, por lo que no detalla las columnas de cada tabla; las dimensiones y medidas descritas se deducen de la Figura 6 y de los reportes que genera el sistema.

¿Qué preguntas concretas puede resolver el sistema?

- ¿Cuántos sismos ocurrieron en un estado y año determinados?
- ¿Cuántas personas estuvieron potencialmente afectadas?
- ¿Cuál fue el sismo de mayor magnitud o impacto en un periodo, y dónde ocurrió?
- ¿Qué localidades de 50 000 habitantes o más están cerca de epicentros de sismos de cierta magnitud?
- ¿Qué alcance tuvo un sismo y qué localidades afectó directamente? Se responde con el mapa de calor.
- ¿Cómo se distribuyen los sismos por magnitud y por mes, y cómo se relacionan la magnitud con la profundidad y con la población afectada?
- ¿Aumentó o disminuyó la actividad sísmica de una región a lo largo de los 125 años de datos?

Estas consultas se pueden personalizar con filtros de periodo, magnitud, localidad, profundidad, número de habitantes y producción económica, y apoyan la planeación territorial, la identificación de zonas en peligro, las rutas de evacuación, la educación en prevención y la investigación científica.

Limitaciones y trabajo futuro

Limitaciones reconocidas por los autores: los sismos no pueden pronosticarse, por lo que el sistema sirve para analizar lo ocurrido y no para predecir eventos futuros. Las fuentes oficiales contienen registros incorrectos que deben eliminarse antes de usarlas. Además, instalar el sistema puede ser complicado para usuarios con poco dominio de las herramientas; los autores lo resuelven con Docker Compose, de modo que basta con tener Docker y ejecutar un comando. Al ser un artículo de divulgación, no incluye una sección formal de limitaciones ni una evaluación cuantitativa del sistema.

Trabajo futuro: habilitar visualizaciones en 3D, incorporar más fuentes de datos oficiales e integrar el sistema con plataformas de alerta temprana.

Artículo 2. Recuperación de información territorial a partir de datos abiertos heterogéneos mediante la construcción de un almacén de datos para la gestión del agua en la Ciudad de México.

¿Qué problema aborda?

La Ciudad de México vive una crisis hídrica causada por la sobreexplotación del acuífero, las fugas en la red y el crecimiento de la población. El Sistema de Aguas de la Ciudad de México (SACMEX) publica datos abiertos de consumo de agua, pero en formatos poco accesibles y sin herramientas para consultarlos, lo que impide usarlos para tomar decisiones basadas en evidencia.

El artículo construye un almacén de datos que reúne esa información dispersa y permite consultarla por año, bimestre, alcaldía y colonia, con un mapa interactivo y un módulo que señala colonias con consumo atípico.

Procesamiento de datos

Fuentes: el recurso Consumo Agua (1er Semestre 2019) del Portal de Datos Abiertos de la CDMX, publicado por SACMEX, con 71 102 registros de los tres primeros bimestres de 2019. Se complementa con una serie meteorológica diaria de Open-Meteo y con la cartografía de OpenStreetMap para el mapa.

Formato: los datos de consumo estaban en archivos CSV, publicados una sola vez, sin versiones ni actualizaciones posteriores a febrero de 2023, y sin un esquema documentado. Cada fila corresponde a una manzana en un periodo de facturación, con su alcaldía, colonia, coordenadas, consumo e índice de desarrollo.

Tratamiento: se aplicó un proceso ETL en cuatro fases con Python y SQL. Primero se leyeron los CSV. Después se validaron y limpiaron, descartando registros con campos vacíos, coordenadas inconsistentes o formatos incompatibles. Luego se cargaron con COPY a tablas temporales (staging), de las que se extrajeron los valores únicos para poblar las dimensiones.

Modelado de la información

El almacén, en PostgreSQL, usa un esquema en estrella con tres dimensiones y dos tablas de hechos.

Dimensiones (entidades):

- **dim_tiempo:** fecha, año y bimestre (181 registros). Son días de la serie climática, aunque los datos de consumo solo tienen tres fechas de lectura, una por bimestre.
- **dim_ubicacion:** alcaldía, colonia, latitud y longitud (1 553 pares alcaldía–colonia de las 16 alcaldías).
- **dim_indice_des:** nivel de desarrollo de la zona, con cuatro niveles: alto, medio, bajo y popular.

Hechos que se miden:

- **fact_consumo_agua:** una fila por manzana y periodo de facturación (70 886 registros). Mide el consumo de agua en metros cúbicos, separado en doméstico y no doméstico, y permite calcular el consumo total y el promedio por cuenta.
- **fact_clima:** la serie climática diaria, que se cruza con el consumo a través del tiempo.

Relación: ambas tablas de hechos comparten la dimensión de tiempo, y la de consumo se conecta también con ubicación e índice de desarrollo. El mismo modelo se publicó como grafo.

¿Qué preguntas concretas puede resolver el sistema?

- ¿Cuánta agua se consume en cada alcaldía y en cada colonia, por año y por bimestre?
- ¿Qué alcaldías consumen más? Cuauhtémoc y Miguel Hidalgo encabezan, seguidas de Benito Juárez, Gustavo A. Madero y Álvaro Obregón.
- ¿En qué bimestre hubo mayor consumo?
- ¿Consumen más las colonias con índice de desarrollo alto que las de índice bajo?
- ¿Cuáles son las diez colonias de mayor consumo?

Limitaciones y trabajo futuro

Limitaciones reconocidas por los autores:

- Todos los resultados provienen de datos sintéticos; nada se ha validado con registros municipales reales.
- No hay un despliegue dinámico en línea: solo una demostración estática, y la API se distribuye para que la ejecute quien la necesite.
- El almacenamiento de objetos solo guarda evidencia; no se consulta de forma analítica, así que todavía no es un lakehouse.
- La regla de detección falla con las anomalías de costo, porque compara montos absolutos y termina marcando obras grandes en lugar de obras con sobreprecio.
- La carga de datos en los dos almacenamientos no es atómica y puede dejar archivos huérfanos.
- El mapa público lee el esquema operativo en lugar de las vistas del almacén, por lo que ambas lecturas podrían no coincidir.

Trabajo futuro propuesto:

- Convertir la capa de objetos en un lakehouse completo con un formato de tabla abierto (Apache Iceberg o Parquet) consultable con DuckDB o Trino.

- Clasificar automáticamente el avance de obra a partir de las fotografías mediante visión por computadora.
- Usar votación cuadrática, modelos de series de tiempo para predecir fechas de conclusión y un criterio de costo calculado por tipo de obra.
- Validar el sistema en otros municipios, midiendo el antes y el después en el tiempo de elaboración de reportes y en las solicitudes de información.

Artículo 3. Un almacén de datos dimensional para el monitoreo geoespacial de obras públicas municipales, con una ruta de evolución.

¿Qué problema aborda?

Las direcciones de obras públicas municipales manejan al mismo tiempo contratistas, presupuestos, supervisores, fotografías de avance, reportes mensuales y actas de entrega-recepción. Sin embargo, la mayoría de los municipios en México trabaja con hojas de cálculo, archivos dispersos o sistemas transaccionales aislados, lo que impide analizar el historial de las obras, detectar retrasos a tiempo y dar a la ciudadanía información confiable para vigilar el gasto público.

El artículo propone un almacén de datos dimensional para el monitoreo geoespacial de obras públicas, aplicado como prototipo al municipio de Temascaltepec, Estado de México con mas de (64 844 habitantes en 55 comunidades). El almacén se complementa con almacenamiento de objetos para guardar evidencia como fotografías y PDF, y busca ofrecer trazabilidad auditable, alertas y participación ciudadana sin los costos de las plataformas empresariales.

trabajo futuro.

Procesamiento de datos

Origen de los datos: por restricciones de privacidad no se usaron registros municipales reales. Todos los datos son sintéticos, producidos con un generador sembrado (Faker): 1 247 obras en 55 comunidades, 127.4 millones de pesos de presupuesto, 14 885 reportes de avance, 3 421 fotografías de evidencia, 2 156 propuestas ciudadanas y 8 723 votos. Las comunidades sí son reales; sus coordenadas se tomaron de OpenStreetMap, con un pequeño desplazamiento para que las obras de una misma comunidad no se encimen.

Formato: en operación, la información llega desde formularios web por rol (director, supervisor, secretaria, planeador y ciudadano). Hay datos estructurados, como texto, coordenadas y montos, y datos no estructurados, como imágenes JPG/PNG y documentos PDF.

Tratamiento: una API REST en Flask/Python recibe cada envío y lo dirige a su destino. Los datos estructurados se guardan en un esquema operativo (OLTP) en PostgreSQL/Supabase. En lugar de un proceso ETL externo, triggers de base de datos pueblan el almacén automáticamente .

(tipo, tamaño y fecha) se registran en el almacén para enlazar ambas capas.

Modelado de la información

El almacén usa un esquema en estrella con diez dimensiones y dos tablas de hechos.

Dimensiones (entidades) y su tipo de cambio lento (SCD):

- **Tipo 2, conservan el historial completo:** obras (dim_work), regiones (dim_region), empresas contratistas (dim_company), personal (dim_staff) y presupuesto (dim_budget). Cada versión guarda su fecha de inicio, su fecha de fin y si es la vigente.
- **Tipo 1, se sobrescriben:** fuentes de financiamiento (dim_source), ciudadanos (dim_citizen) y propuestas (dim_proposal). En ciudadanos y propuestas no se guarda historial para no acumular datos personales innecesarios.
- **Tipo 0, catálogos fijos:** tiempo (dim_time) y tipo de evento (dim_event_type).

Hechos que se miden:

- **fact_audit_events:** una fila por cada evento de auditoría, es decir, una acción realizada sobre una obra por una persona en un momento dado. Clasifica 17 tipos de evento, como creación de obra, cambio de estado, reporte de avance, modificación de presupuesto, carga de imagen o voto. Guarda métricas financieras, métricas de avance y banderas de auditoría, y está particionada por año.
- **fact_work_monthly:** una fila por obra y por mes, a modo de fotografía mensual. Guarda el presupuesto total, el costo acumulado, el saldo, el porcentaje ejercido, el avance físico, los reportes e imágenes registrados, y una bandera de retraso con los días de desfase.

Relación: la tabla de eventos se conecta con las diez dimensiones; la tabla mensual, solo con las cinco de Tipo 2 y con la de tiempo. Sobre ellas se construyen seis vistas analíticas: obras retrasadas, alertas de auditoría, historial de versiones de una obra, participación ciudadana, presupuesto ejercido por fuente de financiamiento y detección de anomalías.

¿Qué preguntas concretas puede resolver el sistema?

- ¿Qué obras van retrasadas y por cuántos días?
- ¿Qué monto de presupuesto estaba vigente el día en que se autorizó un pago, y no solo el monto actual?
- ¿Cuánto presupuesto se ha ejercido por fuente de financiamiento?
- ¿Cuántas propuestas y votos ciudadanos hay por región?
 - ¿Dónde están las obras en el mapa y cuál es su estado (concluida, en proceso o retrasada)?

Limitaciones y trabajo futuro

- Todos los resultados provienen de datos sintéticos; nada se ha validado con registros municipales reales.
- No hay un despliegue dinámico en línea: solo una demostración estática, y la API se distribuye para que la ejecute quien la necesite.
- La regla de detección falla con las anomalías de costo, porque compara montos absolutos y termina marcando obras grandes en lugar de obras con sobreprecio.
- La carga de datos en los dos almacenamientos no es atómica y puede dejar archivos huérfanos.
- El mapa público lee el esquema operativo en lugar de las vistas del almacén, por lo que ambas lecturas podrían no coincidir.

Trabajo futuro propuesto:

- Convertir la capa de objetos en un lakehouse completo con un formato de tabla abierto (Apache Iceberg o Parquet) consultable con DuckDB o Trino.
- Clasificar automáticamente el avance de obra a partir de las fotografías mediante visión por computadora.
- Validar el sistema en otros municipios, midiendo el antes y el después en el tiempo de elaboración de reportes y en las solicitudes de información.